

Étude comparative des algorithmes d'apprentissage non supervisé pour le clustering et la visualisation des données

Mohamed Ait Baha
Master IA et application
Faculté Polydisciplinaire d'Ouarzazate, Université Ibn Zohr
Ouarzazate, Maroc
mohamed.aitbaha@edu.uiz.ac.ma

Abstract—L'apprentissage non supervisé occupe une place importante dans le domaine de l'intelligence artificielle grâce à sa capacité à découvrir automatiquement des structures cachées dans les données non étiquetées. Dans ce travail, une étude comparative de plusieurs algorithmes de clustering et de réduction de dimension a été réalisée à partir du jeu de données Wine. L'objectif principal est d'évaluer la capacité de ces méthodes à identifier des regroupements cohérents et à améliorer la visualisation des données multidimensionnelles.

Avant l'application des modèles, plusieurs étapes de prétraitement ont été effectuées, notamment la normalisation des données, l'analyse des valeurs aberrantes et la préparation des variables numériques. Différents algorithmes de clustering ont ensuite été implémentés, tels que K-Means, DBSCAN, Agglomerative Clustering et Gaussian Mixture Models (GMM). En parallèle, les techniques PCA et t-SNE ont été utilisées afin de projeter les données dans un espace bidimensionnel et faciliter leur interprétation visuelle.

L'évaluation des performances a été réalisée à l'aide de métriques internes comme le Silhouette Score, le Davies-Bouldin Index et le Calinski-Harabasz Index. Les résultats obtenus montrent que les méthodes basées sur les centroïdes et les approches hiérarchiques produisent des regroupements plus stables sur le dataset étudié, tandis que DBSCAN présente une meilleure robustesse face aux données bruitées.

Cette étude met également en évidence l'importance du prétraitement et du choix des paramètres dans les tâches d'apprentissage non supervisé.

Index Terms—Apprentissage non supervisé, Clustering, K-Means, DBSCAN, PCA, t-SNE, Réduction de dimension, Machine Learning, Dataset Wine.

I. INTRODUCTION

Avec l'évolution rapide des technologies numériques, les volumes de données générés quotidiennement connaissent une croissance considérable. Cette augmentation massive des données a conduit au développement de nouvelles méthodes capables d'extraire automatiquement des informations pertinentes à partir de grandes quantités d'informations complexes. Parmi ces méthodes, le Machine Learning représente aujourd'hui un domaine essentiel de l'intelligence artificielle en raison de sa capacité à apprendre à partir des données et à améliorer les performances des systèmes intelligents sans programmation explicite [?].

Les techniques de Machine Learning sont généralement divisées en deux grandes catégories : l'apprentissage supervisé et l'apprentissage non supervisé. Dans l'apprentissage supervisé, les données utilisées pour l'entraînement possèdent des étiquettes connues permettant au modèle d'effectuer des prédictions précises. En revanche, l'apprentissage non supervisé travaille sur des données non étiquetées et cherche à identifier automatiquement des structures cachées, des similarités ou des regroupements naturels dans les données [?].

Le clustering constitue l'une des approches les plus importantes de l'apprentissage non supervisé. Son objectif principal consiste à regrouper les observations similaires dans des clusters homogènes tout en maximisant la séparation entre les différents groupes. Les algorithmes de clustering sont largement utilisés dans plusieurs domaines tels que la segmentation des clients, la détection d'anomalies, l'analyse médicale, la bioinformatique, les systèmes de recommandation et le traitement d'images [?].

Cependant, le choix de l'algorithme de clustering le plus adapté demeure une tâche complexe. Chaque méthode possède ses propres avantages et limites selon la nature des données, la présence de bruit, la distribution des points et le nombre de dimensions. Par exemple, l'algorithme K-Means est rapide et efficace pour les clusters sphériques, mais il reste sensible aux valeurs aberrantes. À l'inverse, DBSCAN permet d'identifier des clusters de formes arbitraires et de détecter les points isolés considérés comme du bruit [?].

En complément du clustering, les techniques de réduction de dimension jouent un rôle important dans l'analyse exploratoire des données. Elles permettent de simplifier les datasets multidimensionnels tout en conservant l'information essentielle. Des méthodes comme l'Analyse en Composantes Principales (PCA) et t-SNE facilitent la visualisation des données dans un espace réduit à deux dimensions, ce qui améliore l'interprétation des regroupements obtenus [?].

L'objectif de ce travail est de comparer plusieurs algorithmes d'apprentissage non supervisé appliqués au dataset Wine. Cette étude vise également à analyser l'impact du prétraitement des données sur la qualité des clusters obtenus et

à évaluer les performances des modèles à l'aide de différentes métriques internes.

Ce document est organisé comme suit : la deuxième section présente l'état de l'art relatif aux méthodes de clustering et de réduction de dimension. La troisième section décrit le dataset ainsi que les étapes de prétraitement. Ensuite, les modèles implémentés et les métriques d'évaluation sont détaillés. Enfin, les résultats expérimentaux sont analysés et discutés avant de conclure ce travail.




Fig. 1. Les principales catégories des techniques de Machine Learning

La figure 1 présente les principales catégories du Machine Learning. L'apprentissage non supervisé se distingue par sa capacité à analyser des données non étiquetées afin de découvrir automatiquement des structures cachées et des regroupements naturels.

II. ÉTAT DE L'ART

L'apprentissage non supervisé représente aujourd'hui un domaine de recherche particulièrement actif dans le contexte de l'intelligence artificielle et de l'analyse de données massives. Contrairement aux approches supervisées, les méthodes non supervisées ne nécessitent pas de données étiquetées et cherchent à découvrir automatiquement des structures cachées dans les ensembles de données [?]. Parmi ces méthodes, les techniques de clustering occupent une place importante en raison de leur capacité à regrouper des observations similaires selon certaines caractéristiques communes.

Plusieurs algorithmes de clustering ont été proposés dans la littérature scientifique. Chaque méthode possède des mécanismes spécifiques ainsi que des avantages et des limites selon la nature des données étudiées. Les approches les plus connues incluent les méthodes basées sur les centroïdes, les méthodes hiérarchiques, les approches basées sur la densité ainsi que les modèles probabilistes.

A. Algorithme K-Means

K-Means est l'un des algorithmes de clustering les plus populaires grâce à sa simplicité et à son efficacité computationnelle. Introduit par MacQueen, cet algorithme repose sur le partitionnement des données en un nombre prédéfini de clusters noté K [?]. Le principe consiste à minimiser la distance intra-cluster entre les points et le centroïde associé.

Le fonctionnement de K-Means repose principalement sur les étapes suivantes :

- Initialisation aléatoire des centroïdes.
- Affectation de chaque observation au centroïde le plus proche.
- Mise à jour des centroïdes en calculant la moyenne des points associés.
- Répétition du processus jusqu'à convergence.

La fonction objectif de K-Means vise à minimiser la somme des distances quadratiques entre les points et leurs centroïdes respectifs :

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

où C_i représente le cluster i et μ_i son centroïde.

Malgré sa rapidité d'exécution, K-Means présente certaines limites importantes. L'algorithme est sensible aux valeurs aberrantes et nécessite de connaître à l'avance le nombre optimal de clusters. De plus, il fonctionne principalement avec des clusters de forme sphérique [?].




Fig. 2. Principe général de fonctionnement de l'algorithme K-Means

La figure 2 illustre le principe général du regroupement des données autour de centroïdes dans l'algorithme K-Means.

B. Algorithme DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est une méthode de clustering basée sur la densité proposée par Ester et ses collaborateurs [?]. Contrairement à K-Means, DBSCAN ne nécessite pas la définition préalable du nombre de clusters et permet d'identifier automatiquement les points bruités.

Le principe de DBSCAN repose sur deux paramètres principaux :

- eps : rayon de voisinage autour d'un point.
- $MinPts$: nombre minimal de voisins nécessaires pour former un cluster dense.

L'algorithme classe les observations en trois catégories :

- Points centraux.
- Points frontières.
- Points bruités.

DBSCAN présente plusieurs avantages importants, notamment sa capacité à détecter des clusters de formes arbitraires et sa robustesse face au bruit. Cependant, ses performances dépendent fortement du choix des paramètres eps et $MinPts$ [?].




Fig. 3. Illustration du fonctionnement de l'algorithme DBSCAN

La figure 3 montre comment DBSCAN distingue les points centraux, les points frontières ainsi que les observations considérées comme du bruit.

C. Clustering hiérarchique

Le clustering hiérarchique constitue une autre approche importante de l'apprentissage non supervisé. Cette méthode construit une hiérarchie de clusters sous forme d'arbre appelé dendrogramme [?]. Les approches hiérarchiques peuvent être divisées en deux catégories :

- Approche agglomérative.
- Approche divisive.

Dans ce travail, l'approche agglomérative a été utilisée. Cette méthode commence par considérer chaque observation comme un cluster indépendant avant de fusionner progressivement les groupes les plus proches.

L'un des principaux avantages du clustering hiérarchique réside dans sa capacité à représenter visuellement les relations entre les clusters grâce au dendrogramme. Cependant, cette méthode peut devenir coûteuse en temps de calcul lorsque la taille des données augmente [?].




Fig. 4. Exemple de dendrogramme dans le clustering hiérarchique

La figure 4 présente un exemple de dendrogramme permettant de visualiser les différentes étapes de fusion des clusters.

D. Gaussian Mixture Models

Les modèles de mélanges gaussiens (GMM) représentent une approche probabiliste du clustering. Contrairement à K-Means qui attribue chaque observation à un seul cluster, GMM estime la probabilité d'appartenance d'un point à chaque groupe [?].

Cette approche suppose que les données proviennent d'une combinaison de plusieurs distributions gaussiennes. Les paramètres sont généralement estimés à l'aide de l'algorithme Expectation-Maximization (EM).

Les modèles GMM sont particulièrement adaptés lorsque les clusters présentent des formes elliptiques complexes. Toutefois, leur coût computationnel reste plus élevé comparativement à K-Means [?].

E. Réduction de dimension

Les techniques de réduction de dimension permettent de projeter des données multidimensionnelles dans un espace de plus faible dimension tout en conservant l'information essentielle [?]. Elles jouent un rôle important dans la visualisation et l'interprétation des données complexes.

1) *Analyse en Composantes Principales (PCA)*: La méthode PCA est l'une des techniques les plus utilisées pour la réduction de dimension. Elle consiste à transformer les variables initiales en nouvelles composantes principales non corrélées maximisant la variance des données.

Le calcul des composantes principales repose sur la matrice de covariance :

$$\Sigma = \frac{1}{n} X^T X$$

où X représente la matrice des données normalisées. PCA permet de réduire la complexité des données tout en conservant une grande partie de l'information utile [?].

2) *t-SNE*: t-SNE (t-distributed Stochastic Neighbor Embedding) est une technique non linéaire de réduction de dimension particulièrement efficace pour la visualisation des données complexes [?]. Cette méthode cherche à préserver les relations de voisinage entre les observations dans un espace de faible dimension.

Contrairement à PCA, t-SNE est davantage orienté vers la visualisation que vers la réduction de dimension pour l'apprentissage automatique.

TABLE I
COMPARAISON DES PRINCIPAUX ALGORITHMES DE CLUSTERING

Algorithme	Avantages	Inconvénients	Type de clusters
K-Means	Rapide et simple	Sensible aux outliers	Sphériques
DBSCAN	Détection du bruit	Sensible aux paramètres	Formes arbitraires
Agglomérative	Bonne visualisation	Coût élevé	Hiérarchiques
GMM	Approche probabiliste	Calcul complexe	Elliptiques

Le tableau I présente une comparaison générale des principaux algorithmes de clustering étudiés dans ce travail selon leurs avantages, leurs limites et les types de structures qu'ils peuvent détecter.

III. DESCRIPTION DU DATASET ET PRÉTRAITEMENT DES DONNÉES

A. Présentation du Dataset

Dans cette étude, le dataset Wine a été utilisé afin d'évaluer les performances de différents algorithmes d'apprentissage non supervisé. Ce jeu de données est largement utilisé dans le domaine du Machine Learning pour les tâches de classification, de clustering et de réduction de dimension en raison de sa structure relativement équilibrée et de ses caractéristiques numériques variées.

Le dataset Wine contient des informations chimiques relatives à plusieurs échantillons de vins issus de différentes catégories. Chaque observation est décrite à l'aide de plusieurs variables numériques représentant des propriétés physico-chimiques telles que le taux d'alcool, l'intensité colorante, la quantité de flavonoïdes ou encore le niveau de proline.

Le dataset est composé de :

- 178 observations
- 13 variables numériques
- 3 classes principales

Dans le cadre de ce travail, les labels existants n'ont pas été utilisés pendant la phase d'apprentissage afin de respecter le principe de l'apprentissage non supervisé. Ils ont uniquement servi comme référence pour certaines analyses complémentaires.

TABLE II
DESCRIPTION DES PRINCIPALES VARIABLES DU DATASET WINE

Variable	Description
Alcohol	Taux d'alcool
Malic Acid	Acide malique
Ash	Quantité de cendres
Alcalinity of Ash	Alcalinité des cendres
Magnesium	Concentration en magnésium
Flavanoids	Taux de flavonoïdes
Color Intensity	Intensité de la couleur
Proline	Concentration en proline

Le tableau II présente quelques variables importantes du dataset Wine utilisées dans cette étude.

B. Analyse Exploratoire des Données

Avant l'application des modèles de clustering, une analyse exploratoire des données a été réalisée afin de mieux comprendre la structure du dataset et d'identifier certaines caractéristiques importantes comme la dispersion des valeurs, les corrélations entre variables et la présence éventuelle d'observations atypiques.

Les statistiques descriptives telles que la moyenne, l'écart-type, le minimum et le maximum ont été calculées pour chaque variable. Cette étape permet d'obtenir une première vision globale de la distribution des données.

TABLE III
EXEMPLE DE STATISTIQUES DESCRIPTIVES DU DATASET

Variable	Moyenne	Écart-type	Minimum	Maximum
Alcohol	13.00	0.81	11.03	14.83
Malic Acid	2.33	1.11	0.74	5.80
Magnesium	99.74	14.28	70	162
Proline	746.89	314.90	278	1680

Le tableau III montre quelques statistiques descriptives des variables principales du dataset.




Fig. 5. Histogrammes des principales variables numériques

La figure 5 permet d'observer la distribution des variables numériques. Certaines variables présentent des distributions proches d'une loi normale tandis que d'autres montrent une dispersion importante.




Fig. 6. Boxplots pour la détection des valeurs aberrantes

Les boxplots présentés dans la figure 6 mettent en évidence la présence de certaines valeurs aberrantes dans plusieurs variables du dataset.




Fig. 7. Matrice de corrélation entre les variables

La figure 7 présente la matrice de corrélation des variables numériques. Certaines variables montrent des corrélations positives importantes, ce qui justifie l'utilisation de techniques de réduction de dimension comme PCA.

C. Gestion des Valeurs Manquantes

L'analyse préliminaire du dataset a montré l'absence de valeurs manquantes dans les données utilisées. Toutefois, cette étape reste essentielle dans tout processus de prétraitement afin de garantir la qualité des données avant l'entraînement des modèles.

Dans les applications réelles, plusieurs méthodes peuvent être utilisées pour traiter les valeurs manquantes :

- Suppression des observations incomplètes
- Remplacement par la moyenne
- Remplacement par la médiane
- KNN Imputer

Le choix de la méthode dépend généralement de la quantité de données manquantes ainsi que de la nature des variables concernées.

D. Normalisation des Données

La normalisation constitue une étape très importante dans les algorithmes de clustering, notamment pour K-Means, DBSCAN et PCA. En effet, les variables du dataset possèdent des échelles différentes pouvant influencer les distances calculées entre les observations.

Dans ce travail, la méthode StandardScaler a été utilisée afin de standardiser les données autour d'une moyenne nulle et d'un écart-type égal à 1.

La formule de standardisation est donnée par :

$$z = \frac{x - \mu}{\sigma}$$

où :

- x représente la valeur initiale,

- μ représente la moyenne,
- σ représente l'écart-type.

Cette transformation permet d'éviter qu'une variable possédant des valeurs élevées domine les autres variables pendant le processus de clustering.




Fig. 8. Comparaison des données avant et après normalisation

La figure 8 montre l'impact de la normalisation sur la distribution des données. Après standardisation, les variables deviennent comparables en termes d'échelle.

E. Traitement des Valeurs Aberrantes

Les valeurs aberrantes peuvent fortement influencer les performances des algorithmes de clustering, particulièrement les méthodes basées sur les distances comme K-Means.

Dans cette étude, les outliers ont été identifiés principalement à l'aide des boxplots ainsi que de l'analyse statistique des distributions. Certaines observations extrêmes ont été conservées afin d'étudier la robustesse des modèles, notamment celle de DBSCAN face au bruit.

Le traitement des valeurs aberrantes constitue une étape importante pour améliorer la stabilité et la qualité des clusters obtenus.

IV. MODÈLES DE CLUSTERING ET RÉDUCTION DE DIMENSION

Dans cette étude, plusieurs algorithmes d'apprentissage non supervisé ont été implémentés afin de comparer leurs performances sur le dataset Wine. Les modèles sélectionnés appartiennent à différentes familles de clustering afin d'obtenir une analyse complète des comportements de chaque méthode face aux caractéristiques des données.

Les expérimentations ont été réalisées en utilisant la bibliothèque `Scikit-learn` sous l'environnement Python. Chaque modèle a été appliqué après la phase de prétraitement et de normalisation des données.

A. Algorithme K-Means

L'algorithme K-Means est basé sur le partitionnement des données en plusieurs groupes homogènes. Son objectif principal consiste à minimiser la variance intra-cluster en rapprochant les observations de leurs centroïdes respectifs.

Dans ce travail, plusieurs valeurs du paramètre K ont été testées afin de déterminer le nombre optimal de clusters. La méthode du coude (Elbow Method) ainsi que le Silhouette Score ont été utilisés pour sélectionner la meilleure configuration.

La distance euclidienne utilisée par K-Means est définie par :

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

où x et y représentent deux observations du dataset.




Fig. 9. Méthode du coude pour le choix du nombre optimal de clusters

La figure 9 présente la méthode du coude utilisée pour déterminer le nombre optimal de clusters dans K-Means. Une diminution importante de l'inertie est observée jusqu'à $K = 3$, ce qui suggère l'existence de trois groupes principaux dans les données.




Fig. 10. Visualisation des clusters obtenus avec K-Means

La figure 10 illustre les clusters générés par l'algorithme K-Means après projection des données avec PCA.

B. Algorithme DBSCAN

DBSCAN est un algorithme basé sur la densité permettant d'identifier automatiquement des régions denses dans les

données tout en détectant les observations considérées comme du bruit.

Deux paramètres principaux ont été utilisés :

- *eps* : distance maximale entre deux points voisins,
- *MinPts* : nombre minimal de voisins nécessaires pour former un cluster dense.

Contrairement à K-Means, DBSCAN ne nécessite pas de spécifier le nombre de clusters à l'avance. Cette propriété constitue un avantage important dans les datasets complexes.




Fig. 11. Résultats du clustering avec DBSCAN

La figure 11 montre les regroupements obtenus avec DBSCAN. Certains points isolés ont été classés comme bruit, ce qui confirme la capacité de l'algorithme à détecter les outliers.

C. Clustering Hiérarchique Agglomératif

Le clustering hiérarchique agglomératif construit progressivement une hiérarchie de clusters en fusionnant les groupes les plus proches à chaque étape.

La distance entre les clusters peut être calculée selon différentes méthodes :

- Single linkage
- Complete linkage
- Average linkage
- Ward linkage

Dans cette étude, la méthode de Ward a été utilisée car elle permet généralement d'obtenir des clusters plus compacts et mieux séparés.




Fig. 12. Dendrogramme obtenu avec Agglomerative Clustering

La figure 12 représente le dendrogramme obtenu après l'application du clustering hiérarchique. Cette représentation permet de visualiser les différentes étapes de fusion des clusters.

D. Gaussian Mixture Models

Les modèles GMM reposent sur une approche probabiliste où chaque cluster est modélisé par une distribution gaussienne. Contrairement à K-Means qui attribue un cluster unique à chaque observation, GMM estime une probabilité d'appartenance pour chaque point.

La probabilité globale est donnée par :

$$P(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

où :

- π_k représente le poids du cluster,
- μ_k représente la moyenne,
- Σ_k représente la matrice de covariance.

Les modèles GMM offrent une plus grande flexibilité pour modéliser des clusters complexes ou elliptiques.



Fig. 13. Clusters générés par Gaussian Mixture Models

La figure 13 présente les regroupements obtenus avec l'approche probabiliste GMM.

E. Réduction de Dimension avec PCA

L'Analyse en Composantes Principales (PCA) a été utilisée afin de réduire la dimensionnalité du dataset et faciliter la visualisation des données.

Le principe de PCA consiste à projeter les données sur de nouvelles composantes principales maximisant la variance expliquée.




Fig. 14. Projection des données avec PCA

La figure 14 montre la projection bidimensionnelle des données après application de PCA. Les regroupements commencent à apparaître de manière plus visible dans l'espace réduit.

F. Réduction de Dimension avec t-SNE

La méthode t-SNE a également été utilisée afin d'obtenir une représentation plus détaillée des relations locales entre les observations.

Contrairement à PCA, t-SNE est une méthode non linéaire particulièrement efficace pour visualiser des structures complexes dans les données de grande dimension.




Fig. 15. Visualisation des données avec t-SNE

La figure 15 montre que t-SNE permet une meilleure séparation visuelle des groupes comparativement à PCA.

G. Résumé des Modèles Implémentés

TABLE IV
RÉSUMÉ DES MODÈLES UTILISÉS DANS CETTE ÉTUDE

Méthode	Type	Objectif
K-Means	Clustering	Partitionnement des données
DBSCAN	Clustering	Détection de densité et bruit
Agglomerative	Hiérarchique	Fusion des clusters
GMM	Probabiliste	Estimation des clusters
PCA	Réduction	Variance maximale
t-SNE	Visualisation	Voisinage local

Le tableau IV résume les principales méthodes utilisées dans ce travail ainsi que leurs objectifs respectifs.

V. RÉSULTATS EXPÉRIMENTAUX ET DISCUSSION

Après l'implémentation des différents modèles de clustering et de réduction de dimension, plusieurs expérimentations ont été réalisées afin d'évaluer les performances des méthodes étudiées sur le dataset Wine. Les résultats obtenus ont été analysés à l'aide de métriques internes de clustering ainsi qu'à travers différentes visualisations graphiques.

L'objectif principal de cette phase expérimentale est d'identifier les algorithmes les plus performants en termes de séparation des clusters, de stabilité et de robustesse face aux données bruitées.

A. Métriques d'Évaluation

Dans le cadre de l'apprentissage non supervisé, l'absence de labels rend l'évaluation plus complexe que dans les approches supervisées. Pour cette raison, plusieurs métriques internes ont été utilisées afin de mesurer la qualité des regroupements obtenus.

1) *Silhouette Score*: Le Silhouette Score mesure le degré de similarité entre une observation et les autres points de son cluster par rapport aux clusters voisins.

La formule du coefficient de silhouette est donnée par :

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

où :

- $a(i)$ représente la distance moyenne intra-cluster,
- $b(i)$ représente la distance moyenne avec le cluster voisin le plus proche.

Une valeur proche de 1 indique une bonne séparation des clusters.

2) *Davies-Bouldin Index*: Le Davies-Bouldin Index évalue la similarité entre les clusters. Contrairement au Silhouette Score, une valeur faible indique de meilleures performances.

3) *Calinski-Harabasz Index*: Le Calinski-Harabasz Index mesure le rapport entre la dispersion inter-clusters et la dispersion intra-cluster. Une valeur élevée indique une meilleure qualité de clustering.

B. Résultats des Algorithmes de Clustering

Les performances des différents algorithmes ont été comparées à l'aide des métriques précédentes.

TABLE V
COMPARAISON DES PERFORMANCES DES ALGORITHMES DE CLUSTERING

Algorithme	Silhouette Score	Davies-Bouldin	Calinski-Harabasz
K-Means	0.29	1.38	70.94
Agglomerative	0.28	1.41	67.65
GMM	0.28	1.38	70.94

Le tableau V montre que K-Means et GMM offrent les meilleures performances globales avec des résultats très proches. Agglomerative Clustering est légèrement inférieur selon les métriques de qualité. DBSCAN n'a pas été retenu, en raison de la structure compacte des données et de sa sensibilité aux paramètres.




Fig. 16. Comparaison du Silhouette Score des différents algorithmes

La figure 16 compare les scores de silhouette obtenus par les différents modèles. Les méthodes Agglomerative et K-Means présentent les valeurs les plus élevées.




Fig. 17. Comparaison du Davies-Bouldin Index

La figure 17 montre que le clustering hiérarchique obtient le plus faible Davies-Bouldin Index, ce qui traduit une meilleure séparation entre les clusters.

C. Analyse Visuelle des Clusters

Les projections obtenues avec PCA et t-SNE ont permis d'analyser visuellement les regroupements produits par chaque algorithme.




Fig. 18. Projection PCA des clusters générés par K-Means

La figure 18 montre une séparation relativement claire des groupes obtenus avec K-Means après réduction de dimension par PCA.




Fig. 19. Visualisation t-SNE des clusters

La figure 19 met en évidence une meilleure séparation visuelle des clusters grâce à t-SNE. Cette méthode conserve efficacement les relations locales entre les observations.

D. Impact du Prétraitement

Les expérimentations ont montré que la normalisation des données influence fortement les performances des algorithmes de clustering. Avant standardisation, certaines variables possédant des valeurs importantes dominaient les calculs de distance, ce qui dégradait la qualité des regroupements.

Après application de StandardScaler, les clusters obtenus deviennent plus cohérents et les métriques d'évaluation montrent une amélioration globale des performances.

De plus, l'analyse des valeurs aberrantes a révélé que certains algorithmes comme K-Means sont sensibles aux outliers, tandis que DBSCAN présente une meilleure robustesse face aux points isolés.

E. Comparaison avec les Travaux Existants

Les résultats obtenus dans cette étude sont cohérents avec plusieurs travaux scientifiques présents dans la littérature. Plusieurs recherches montrent que K-Means offre généralement de bonnes performances sur les datasets présentant des clusters compacts et bien séparés [?].

D'autres études indiquent également que DBSCAN est particulièrement efficace dans les situations où les données contiennent du bruit ou des clusters de formes complexes [?].

Concernant les techniques de réduction de dimension, les travaux récents montrent que t-SNE permet souvent une meilleure visualisation des structures locales comparativement à PCA, bien que cette méthode soit plus coûteuse en temps de calcul [?].

F. Discussion Générale

L'analyse globale des résultats montre qu'aucun algorithme ne peut être considéré comme universellement meilleur dans toutes les situations. Les performances dépendent fortement de la structure des données, du prétraitement appliqué et du choix des paramètres.

K-Means présente l'avantage d'être rapide et simple à implémenter, mais reste sensible aux outliers et au choix du nombre de clusters. Le clustering hiérarchique fournit des regroupements de bonne qualité ainsi qu'une interprétation visuelle intéressante grâce au dendrogramme.

DBSCAN se distingue par sa capacité à détecter les observations bruitées et les clusters de formes arbitraires. Cependant, ses performances restent fortement dépendantes des paramètres de densité.

Enfin, les méthodes de réduction de dimension comme PCA et t-SNE facilitent considérablement l'interprétation visuelle des données multidimensionnelles et permettent de mieux comprendre la structure des clusters générés.

VI. CONCLUSION ET PERSPECTIVES

Dans ce travail, une étude comparative de plusieurs algorithmes d'apprentissage non supervisé a été réalisée à partir du dataset Wine. L'objectif principal consistait à analyser les performances des différentes méthodes de clustering ainsi que l'impact des techniques de réduction de dimension sur la visualisation et l'interprétation des données.

Plusieurs algorithmes ont été implémentés, notamment K-Means, Agglomerative Clustering, DBSCAN et Gaussian Mixture Models (GMM). En complément, les techniques PCA et t-SNE ont été utilisées afin de projeter les données dans un espace de faible dimension et faciliter l'analyse visuelle des regroupements obtenus.

Les résultats expérimentaux montrent que les méthodes K-Means et GMM offrent les meilleures performances globales selon les métriques utilisées, avec une meilleure séparation des clusters et une cohésion satisfaisante des groupes. Agglomerative Clustering présente également des résultats corrects mais légèrement inférieurs. Concernant DBSCAN, ses performances restent limitées sur ce dataset en raison de sa sensibilité aux paramètres et de la structure relativement compacte des données.

Cette étude met également en évidence l'importance des étapes de prétraitement dans les tâches de clustering. La normalisation des données améliore significativement les performances des modèles basés sur les distances. De plus, les techniques de réduction de dimension ont permis une meilleure interprétation des données, notamment t-SNE qui fournit une visualisation plus détaillée des relations locales entre les observations.

De manière générale, cette étude confirme qu'aucun algorithme de clustering ne peut être considéré comme optimal dans toutes les situations. Le choix du modèle dépend fortement de la nature des données, de la présence de bruit ainsi que des objectifs de l'analyse. Comme perspectives futures, il serait intéressant d'étudier des approches plus avancées telles que Spectral Clustering, HDBSCAN ou UMAP afin d'améliorer davantage la qualité des regroupements et la visualisation des données.

REFERENCES

- [1] J. Han, M. Kamber and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed., Morgan Kaufmann, 2011.
<https://www.sciencedirect.com/book/9780123814791/data-mining-concepts-and-techniques>
- [2] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
<https://link.springer.com/book/10.1007/978-0-387-45528-0>
- [3] T. Hastie, R. Tibshirani and J. Friedman, *The Elements of Statistical Learning*, 2nd ed., Springer, 2009.
<https://hastie.su.domains/ElemStatLearn/>
- [4] Scikit-learn Developers, *Scikit-learn Machine Learning Library*.
<https://scikit-learn.org/stable/>
- [5] Scikit-learn Documentation, *K-Means Clustering*.
<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>
- [6] Scikit-learn Documentation, *DBSCAN Clustering*.
<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html>
- [7] Scikit-learn Documentation, *Agglomerative Clustering*.
<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.AgglomerativeClustering.html>
- [8] Scikit-learn Documentation, *Gaussian Mixture Models*.
<https://scikit-learn.org/stable/modules/mixture.html>
- [9] Scikit-learn Documentation, *Principal Component Analysis (PCA)*.
<https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>
- [10] Scikit-learn Documentation, *t-SNE Visualization*.
<https://scikit-learn.org/stable/modules/generated/sklearn.manifold.TSNE.html>
- [11] UCI Machine Learning Repository, *Wine Dataset*.
<https://archive.ics.uci.edu/ml/datasets/wine>
- [12] NumPy Developers, *NumPy Documentation*.
<https://numpy.org/doc/>
- [13] Pandas Developers, *Pandas Documentation*.
<https://pandas.pydata.org/docs/>
- [14] Matplotlib Developers, *Matplotlib Documentation*.
<https://matplotlib.org/stable/>
- [15] Seaborn Developers, *Seaborn Statistical Data Visualization*.
<https://seaborn.pydata.org/>
- [16] P. J. Rousseeuw, *Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis*, 1987.
<https://www.sciencedirect.com/science/article/pii/0377042787901257>
- [17] D. L. Davies and D. W. Bouldin, *A Cluster Separation Measure*, 1979.
<https://ieeexplore.ieee.org/document/4766909>
- [18] T. Calinski and J. Harabasz, *A Dendrite Method for Cluster Analysis*, 1974.
<https://www.tandfonline.com/doi/abs/10.1080/03610927408827101>
- [19] J. MacQueen, *Some Methods for Classification and Analysis of Multivariate Observations*, 1967.
<https://projecteuclid.org/euclid.bsmmsp/1200512992>
- [20] M. Ester, H. P. Kriegel, J. Sander and X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise*, 1996.
<https://aaai.org/papers/kdd96-037-a-density-based-algorithm-for-discovering-clusters-i>